



Alunos da equipe:

Equipe 03

- Gustavo Costa de Souza
- Marcos Vinicius de Melo
- Marcus Eneas Silveira Galvao do Rio Apa II
- Patrícia Verdugo Pascoal
- Rodrigo de Araujo
- William de Souza Alencar

Seed utilizado: 2038

(Ano atual com 4 dígitos + 2 algarismos do dígito verificador do CPF de um dos integrantes)

Especificações:

O trabalho pode ser feito por uma equipe de 1 a 6 integrantes.

Para cada problema, preencher as colunas dos quadros com o que pede.

Além disso, fazer as solicitações pedidas antes dos quadros.

CLASSIFICAÇÃO

Para o experimento de Classificação:

- Ordenar pela Acurácia (descendente), ou seja, a técnica de melhor acurácia ficará em primeiro na tabela.
- Após o quadro colocar:
 - Um resultado com 3 linhas com a predição de novos casos para a técnica/parâmetro de maior Acurácia (criar um arquivo com novos casos à sua escolha)
 - A lista de comandos emitidos no RStudio para conseguir os resultados obtidos

Veículo

Técnica	Parâmetro	Acurácia	Matriz de Confusão
---------	-----------	----------	--------------------

SVM – CV	C=100 Sigma=0.015	0.82	<div>[1] "Estimativas do modelo: SVM CV grid search"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Reference</div> <div>Prediction bus opel saab van</div> <div>bus 42 3 1 1</div> <div>opel 0 30 13 0</div> <div>saab 0 7 28 0</div> <div>van 1 2 1 38</div> <div>Overall Statistics</div> <div>Accuracy : 0.8263</div> <div>95% CI : (0.7602, 0.8805)</div> <div>No Information Rate : 0.2575</div> <div>P-Value [Acc > NIR] : <2e-16</div> <div>Kappa : 0.7685</div> <div>McNemar's Test P-Value : 0.1851</div> <div>Statistics by Class:</div> <div>Class: bus Class: opel Class: saab Class: van</div> <div>Sensitivity 0.9767 0.7143 0.6512 0.9744</div> <div>Specificity 0.9597 0.8960 0.9435 0.9688</div> <div>Pos Pred Value 0.8936 0.6977 0.8000 0.9048</div> <div>Neg Pred Value 0.9917 0.9032 0.8864 0.9920</div> <div>Prevalence 0.2575 0.2515 0.2575 0.2335</div> <div>Detection Rate 0.2515 0.1796 0.1677 0.2275</div> <div>Detection Prevalence 0.2814 0.2575 0.2096 0.2515</div> <div>Balanced Accuracy 0.9682 0.8051 0.7974 0.9716</div>
SVM – Hold-out	C=1 Sigma=0.07156	0.73	<div>[1] "Estimativas do modelo: SVM hold-out"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Reference</div> <div>Prediction bus opel saab van</div> <div>bus 41 2 2 1</div> <div>opel 0 18 13 0</div> <div>saab 0 20 26 1</div> <div>van 2 2 2 37</div> <div>Overall Statistics</div> <div>Accuracy : 0.7305</div> <div>95% CI : (0.6565, 0.7962)</div> <div>No Information Rate : 0.2575</div> <div>P-Value [Acc > NIR] : <2e-16</div> <div>Kappa : 0.6406</div> <div>McNemar's Test P-Value : 0.2272</div> <div>Statistics by Class:</div> <div>Class: bus Class: opel Class: saab Class: van</div> <div>Sensitivity 0.9535 0.4286 0.6047 0.9487</div> <div>Specificity 0.9597 0.8960 0.8306 0.9531</div> <div>Pos Pred Value 0.8913 0.5806 0.5532 0.8605</div> <div>Neg Pred Value 0.9835 0.8235 0.8583 0.9839</div> <div>Prevalence 0.2575 0.2515 0.2575 0.2335</div> <div>Detection Rate 0.2455 0.1078 0.1557 0.2216</div> <div>Detection Prevalence 0.2754 0.1856 0.2814 0.2575</div> <div>Balanced Accuracy 0.9566 0.6623 0.7176 0.9509</div>
RF – CV	mtry=7	0.73	<div>[1] "Estimativas do modelo: RF CV grid search"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Reference</div> <div>Prediction bus opel saab van</div> <div>bus 41 2 2 1</div> <div>opel 0 21 16 0</div> <div>saab 0 13 22 0</div> <div>van 2 6 3 38</div> <div>Overall Statistics</div> <div>Accuracy : 0.7305</div> <div>95% CI : (0.6565, 0.7962)</div> <div>No Information Rate : 0.2575</div> <div>P-Value [Acc > NIR] : < 2e-16</div> <div>Kappa : 0.6411</div> <div>McNemar's Test P-Value : 0.03388</div> <div>Statistics by Class:</div> <div>Class: bus Class: opel Class: saab Class: van</div> <div>Sensitivity 0.9535 0.5000 0.5116 0.9744</div> <div>Specificity 0.9597 0.8720 0.8952 0.9141</div> <div>Pos Pred Value 0.8913 0.5676 0.6286 0.7755</div> <div>Neg Pred Value 0.9835 0.8385 0.8409 0.9915</div> <div>Prevalence 0.2575 0.2515 0.2575 0.2335</div> <div>Detection Rate 0.2455 0.1257 0.1317 0.2275</div> <div>Detection Prevalence 0.2754 0.2216 0.2096 0.2934</div> <div>Balanced Accuracy 0.9566 0.6860 0.7034 0.9442</div>

RNA – CV	size=21 decay=0.7	0.72	<div>[1] "Estimativas do modelo: RNA CV grid search"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Reference</div> <div>Prediction bus opel saab van</div> <div>bus 41 2 1 0</div> <div>opel 0 25 23 0</div> <div>saab 1 15 17 1</div> <div>van 1 0 2 38</div> <div>Overall Statistics</div> <div>Accuracy : 0.7246</div> <div>95% CI : (0.6502, 0.7907)</div> <div>No Information Rate : 0.2575</div> <div>P-Value [Acc > NIR] : < 2.2e-16</div> <div>Kappa : 0.6328</div> <div>McNemar's Test P-Value : NA</div> <div>Statistics by Class:</div> <div>Class: bus Class: opel Class: saab Class: van</div> <div>Sensitivity 0.9535 0.5952 0.3953 0.9744</div> <div>Specificity 0.9758 0.8160 0.8629 0.9766</div> <div>Pos Pred Value 0.9318 0.5208 0.5000 0.9268</div> <div>Neg Pred Value 0.9837 0.8571 0.8045 0.9921</div> <div>Prevalence 0.2575 0.2515 0.2575 0.2335</div> <div>Detection Rate 0.2455 0.1497 0.1018 0.2275</div> <div>Detection Prevalence 0.2635 0.2874 0.2036 0.2455</div> <div>Balanced Accuracy 0.9646 0.7056 0.6291 0.9755</div>
RF – Hold-out	mtry=10	0.71	<div>[1] "Estimativas do modelo: RF hold-out"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Reference</div> <div>Prediction bus opel saab van</div> <div>bus 40 2 3 1</div> <div>opel 0 22 18 0</div> <div>saab 0 12 19 0</div> <div>van 3 6 3 38</div> <div>Overall Statistics</div> <div>Accuracy : 0.7126</div> <div>95% CI : (0.6376, 0.7799)</div> <div>No Information Rate : 0.2575</div> <div>P-Value [Acc > NIR] : < 2e-16</div> <div>Kappa : 0.6173</div> <div>McNemar's Test P-Value : 0.01272</div> <div>Statistics by Class:</div> <div>Class: bus Class: opel Class: saab Class: van</div> <div>Sensitivity 0.9302 0.5238 0.4419 0.9744</div> <div>Specificity 0.9516 0.8560 0.9032 0.9062</div> <div>Pos Pred Value 0.8696 0.5500 0.6129 0.7600</div> <div>Neg Pred Value 0.9752 0.8425 0.8235 0.9915</div> <div>Prevalence 0.2575 0.2515 0.2575 0.2335</div> <div>Detection Rate 0.2395 0.1317 0.1138 0.2275</div> <div>Detection Prevalence 0.2754 0.2395 0.1856 0.2994</div> <div>Balanced Accuracy 0.9409 0.6899 0.6725 0.9403</div>
KNN	k=1	0.62	<div>[1] "Estimativas do modelo: KNN"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Reference</div> <div>Prediction bus opel saab van</div> <div>bus 38 2 5 1</div> <div>opel 0 13 20 1</div> <div>saab 4 21 16 0</div> <div>van 1 6 2 37</div> <div>Overall Statistics</div> <div>Accuracy : 0.6228</div> <div>95% CI : (0.5446, 0.6965)</div> <div>No Information Rate : 0.2575</div> <div>P-Value [Acc > NIR] : <2e-16</div> <div>Kappa : 0.4972</div> <div>McNemar's Test P-Value : 0.2604</div> <div>Statistics by Class:</div> <div>Class: bus Class: opel Class: saab Class: van</div> <div>Sensitivity 0.8837 0.30952 0.37209 0.9487</div> <div>Specificity 0.9355 0.83200 0.79839 0.9297</div> <div>Pos Pred Value 0.8261 0.38235 0.39024 0.8043</div> <div>Neg Pred Value 0.9587 0.78195 0.78571 0.9835</div> <div>Prevalence 0.2575 0.25150 0.25749 0.2335</div> <div>Detection Rate 0.2275 0.07784 0.09581 0.2216</div> <div>Detection Prevalence 0.2754 0.20359 0.24551 0.2754</div> <div>Balanced Accuracy 0.9096 0.57076 0.58524 0.9392</div>

RNA – Hold-out	size=5 decay=0.1	0.50	<div>[1] "Estimativas do modelo: RNA hold-out"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Prediction bus opel saab van</div> <div>bus 5 0 0 0</div> <div>opel 0 0 0 0</div> <div>saab 38 37 43 2</div> <div>van 0 5 0 37</div> <div>Overall Statistics</div> <div>Accuracy : 0.509</div> <div>95% CI : (0.4306, 0.587)</div> <div>No Information Rate : 0.2575</div> <div>P-Value [Acc > NIR] : 3.42e-12</div> <div>Kappa : 0.344</div> <div>McNemar's Test P-Value : NA</div> <div>Statistics by Class:</div> <div>Class: bus Class: opel Class: saab Class: van</div> <div>Sensitivity 0.11628 0.0000 1.0000 0.9487</div> <div>Specificity 1.00000 1.0000 0.3790 0.9609</div> <div>Pos Pred Value 1.00000 NaN 0.3583 0.8810</div> <div>Neg Pred Value 0.76543 0.7485 1.0000 0.9840</div> <div>Prevalence 0.25749 0.2515 0.2575 0.2335</div> <div>Detection Rate 0.02994 0.0000 0.2575 0.2216</div> <div>Detection Prevalence 0.02994 0.0000 0.7186 0.2515</div> <div>Balanced Accuracy 0.55814 0.5000 0.6895 0.9548</div>
----------------	---------------------	------	---

O modelo que obteve o melhor desempenho foi o SVM com cross-validation, alcançando uma acurácia de 0,82 com os parâmetros custo (C) = 100 e sigma = 0,015. Esse resultado indica que a técnica de SVM, aliada à validação cruzada e ao ajuste adequado de parâmetros, proporcionou maior capacidade de generalização em comparação aos demais modelos avaliados.

Com base no modelo selecionado, a imagem abaixo apresenta a predição de três novos casos realizada pelo algoritmo SVM.

	Comp	Circ	DCirc	RadRa	PrAxisRa	MaxLRa	ScatRa	Elong	PrAxisRect	MaxLRect	ScVarMaxis	ScVarMaxis	RadGyr	SkewMaxis	Skewmaxis	Kurtmaxis	KurtMaxis	HolIRa	predictsvm
1	85	38	73	168	62	0	152	32	10	149	166	369	174	60	0	6	177	187	saab
2	114	60	116	219	76	20	217	42	33	168	233	645	230	83	24	19	198	206	saab
3	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	opel

Abaixo são os comandos no R Studio para chegar no resultado.

```
pacotes <- c("caret", "e1071", "mlbench", "mice")

# Instalando e carregando os pacotes necessarios
if(sum(as.numeric(!pacotes %in% installed.packages()))!=0){
  instalador <- pacotes[!pacotes %in% installed.packages()]
  for(i in 1:length(instalador)) {
    install.packages(instalador, dependencies = T)
    break()}
  sapply(pacotes, require, character = T)
} else {
  sapply(pacotes, require, character = T)
}

# Configurando o seed
SEED <- 2038
set.seed(SEED)
```

```
# função para dividir as bases
split_train_test <- function(df, target_var) {
  set.seed(SEED)
  indexes <- createDataPartition(df[[target_var]], p=0.80,
list=FALSE)
  train <- df[indexes,]
  test <- df[-indexes, ]
  return(list(train=train, test=test))
}

print_cf <- function(name, df_test, cf_factor, model) {
  print(paste("Estimativas do modelo: ", name))
  predict.model <- predict(model, df_test)

  print("Confusion matrix")
  print(confusionMatrix(predict.model, cf_factor))

  return(predict.model)
}

setwd("C:/Users/rodri/machine-learning/UFPR-IAAP/IAA008 -
Aprendizado de máquina")

# Veículos

df_veiculos <- read.csv("base/06 - Veículos/6 - Veiculos -
Dados.csv")
#View(df_veiculos)
temp_df <- df_veiculos
temp_df$a <- NULL
imp <- mice(temp_df)
df_veiculos <- complete(imp, 1)
df_veiculos[["tipo"]] <- as.factor(df_veiculos[["tipo"]])
View(df_veiculos)

# Divisão da base de dados
split_df <- split_train_test(df_veiculos, "tipo")
train_veiculo = split_df$train
test_veiculo = split_df$test

tipo_fct <- as.factor(test_veiculo$tipo)

ctrl <- trainControl(method="cv", number=10)

# KNN
tuneGrid_knn <- expand.grid(k=c(1,3,5,7,9))
set.seed(SEED)
knn <- train(tipo~., data=train_veiculo, method = "knn", tuneGrid =
tuneGrid_knn)
```

```
knn
predict.knn <- print_cf("KNN", test_veiculo, tipo_fct, knn)

# RNA Hold-out
set.seed(SEED)
rna <- train(tipo~., data=train_veiculo, method = "nnet", trace =
FALSE)
rna
predict.rna <- print_cf("RNA hold-out", test_veiculo, tipo_fct, rna)

# RNA CV
set.seed(SEED)
rna_cv <- train(tipo~., data=train_veiculo, method = "nnet", trace =
FALSE, trControl = ctrl)
rna_cv
predict.rna_cv <- print_cf("RNA CV", test_veiculo, tipo_fct, rna_cv)

# RNA grid search
grid_rna <- expand.grid(size = seq(from=1,to=45, by=10),
decay=seq(from=0.1,to=0.9,by=0.3))
set.seed(SEED)
rna_grid <- train(tipo~., data=train_veiculo, method = "nnet", trace
= FALSE, trControl = ctrl, tuneGrid = grid_rna)
rna_grid
predict.rna_cv_grid <- print_cf("RNA CV grid search", test_veiculo,
tipo_fct, rna_grid)

# SVM
set.seed(SEED)
svm <- train(tipo~., data = train_veiculo, method = "svmRadial")
svm
predict.svm <- print_cf("SVM hold-out", test_veiculo, tipo_fct, svm)

# SVM CV
set.seed(SEED)
svm_cv <- train(tipo~., data = train_veiculo, method = "svmRadial",
trControl = ctrl)
svm_cv
predict.svm_cv <- print_cf("SVM CV", test_veiculo, tipo_fct, svm_cv)

# SVM CV Grid
grid_cv <- expand.grid(C=c(1,2,10,50,100), sigma=c(.01,.015,.2))
set.seed(SEED)
svm_cv_grid <- train(tipo~., data = train_veiculo, method =
"svmRadial", trControl = ctrl, tuneGrid=grid_cv)
svm_cv_grid
predict.svm_cv_grid <- print_cf("SVM CV grid search", test_veiculo,
tipo_fct, svm_cv_grid)

# Random forest
set.seed(SEED)
rf <- train(tipo~., data = train_veiculo, method="rf")
```

```
rf
predict.rf <- print_cf("RF hold-out", test_veiculo, tipo_fct, rf)

# RF CV
set.seed(SEED)
rf_cv <- train(tipo~., data = train_veiculo, method="rf", trControl
= ctrl)
rf_cv
predict.rf_cv <- print_cf("RF CV", test_veiculo, tipo_fct, rf_cv)

# RF CV grid search
grid_rf = expand.grid(mtry=c(2,5,7,9))
set.seed(SEED)
rf_cv_grid <- train(tipo~., data = train_veiculo, method="rf",
trControl = ctrl, tuneGrid = grid_rf)
rf_cv_grid
predict.rf_cv_grid <- print_cf("RF CV grid search", test_veiculo,
tipo_fct, rf_cv_grid)

### Predições
new_data <- read.csv("base/06 - Veículos/6 - Veiculos - Dados -
Novos Casos.csv")
View(new_data)

predict.svm <- predict(svm_cv_grid, new_data)
new_data$tipo <- NULL
result <- cbind(new_data, predict.svm)
View(result)
```

Diabetes

Técnica	Parâmetro	Acurácia	Matriz de Confusão
---------	-----------	----------	--------------------

RF – CV	mtry=5	0.82	<div>[1] "Estimativas do modelo: RF CV grid search"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Reference</div> <div>Prediction neg pos</div> <div>neg 90 17</div> <div>pos 10 36</div> <div>Accuracy : 0.8235</div> <div>95% CI : (0.7537, 0.8804)</div> <div>No Information Rate : 0.6536</div> <div>P-Value [Acc > NIR] : 2.528e-06</div> <div>Kappa : 0.5978</div> <div>Mcnemar's Test P-Value : 0.2482</div> <div>Sensitivity : 0.9000</div> <div>Specificity : 0.6792</div> <div>Pos Pred Value : 0.8411</div> <div>Neg Pred Value : 0.7826</div> <div>Prevalence : 0.6536</div> <div>Detection Rate : 0.5882</div> <div>Detection Prevalence : 0.6993</div> <div>Balanced Accuracy : 0.7896</div> <div>'Positive' Class : neg</div>
SVM – Hold-out	C=0.25 Sigma=0.128	0.81	<div>[1] "Estimativas do modelo: SVM hold-out"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Reference</div> <div>Prediction neg pos</div> <div>neg 96 24</div> <div>pos 4 29</div> <div>Accuracy : 0.817</div> <div>95% CI : (0.7465, 0.8748)</div> <div>No Information Rate : 0.6536</div> <div>P-Value [Acc > NIR] : 6.204e-06</div> <div>Kappa : 0.5565</div> <div>Mcnemar's Test P-Value : 0.0003298</div> <div>Sensitivity : 0.9600</div> <div>Specificity : 0.5472</div> <div>Pos Pred Value : 0.8000</div> <div>Neg Pred Value : 0.8788</div> <div>Prevalence : 0.6536</div> <div>Detection Rate : 0.6275</div> <div>Detection Prevalence : 0.7843</div> <div>Balanced Accuracy : 0.7536</div> <div>'Positive' Class : neg</div>

SVM – CV	C=0.25 Sigma=0.128	0.81	<div>[1] "Estimativas do modelo: SVM CV"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Reference</div> <div>Prediction neg pos</div> <div>neg 96 24</div> <div>pos 4 29</div> <div>Accuracy : 0.817</div> <div>95% CI : (0.7465, 0.8748)</div> <div>No Information Rate : 0.6536</div> <div>P-Value [Acc > NIR] : 6.204e-06</div> <div>Kappa : 0.5565</div> <div>Mcnemar's Test P-Value : 0.0003298</div> <div>Sensitivity : 0.9600</div> <div>Specificity : 0.5472</div> <div>Pos Pred Value : 0.8000</div> <div>Neg Pred Value : 0.8788</div> <div>Prevalence : 0.6536</div> <div>Detection Rate : 0.6275</div> <div>Detection Prevalence : 0.7843</div> <div>Balanced Accuracy : 0.7536</div> <div>'Positive' Class : neg</div>
RNA – CV	size=3 decay=0.1	0.79	<div>[1] "Estimativas do modelo: RNA CV"</div> <div>[1] "Confusion matrix"</div> <div>Confusion Matrix and Statistics</div> <div>Reference</div> <div>Prediction neg pos</div> <div>neg 96 28</div> <div>pos 4 25</div> <div>Accuracy : 0.7908</div> <div>95% CI : (0.7178, 0.8523)</div> <div>No Information Rate : 0.6536</div> <div>P-Value [Acc > NIR] : 0.0001499</div> <div>Kappa : 0.4831</div> <div>Mcnemar's Test P-Value : 4.785e-05</div> <div>Sensitivity : 0.9600</div> <div>Specificity : 0.4717</div> <div>Pos Pred Value : 0.7742</div> <div>Neg Pred Value : 0.8621</div> <div>Prevalence : 0.6536</div> <div>Detection Rate : 0.6275</div> <div>Detection Prevalence : 0.8105</div> <div>Balanced Accuracy : 0.7158</div> <div>'Positive' Class : neg</div>

RF – Hold-out	mtry=2	0.79	<p>[1] "Estimativas do modelo: RF hold-out"</p> <p>[1] "Confusion matrix"</p> <p>Confusion Matrix and Statistics</p> <p>Reference</p> <p>Prediction neg pos</p> <p>neg 91 22</p> <p>pos 9 31</p> <p>Accuracy : 0.7974</p> <p>95% CI : (0.7249, 0.858)</p> <p>No Information Rate : 0.6536</p> <p>P-Value [Acc > NIR] : 7.169e-05</p> <p>Kappa : 0.5252</p> <p>Mcnemar's Test P-Value : 0.03114</p> <p>Sensitivity : 0.9100</p> <p>Specificity : 0.5849</p> <p>Pos Pred Value : 0.8053</p> <p>Neg Pred Value : 0.7750</p> <p>Prevalence : 0.6536</p> <p>Detection Rate : 0.5948</p> <p>Detection Prevalence : 0.7386</p> <p>Balanced Accuracy : 0.7475</p> <p>'Positive' Class : neg</p>
KNN	k=9	0.76	<p>[1] "Estimativas do modelo: KNN"</p> <p>[1] "Confusion matrix"</p> <p>Confusion Matrix and Statistics</p> <p>Reference</p> <p>Prediction neg pos</p> <p>neg 85 21</p> <p>pos 15 32</p> <p>Accuracy : 0.7647</p> <p>95% CI : (0.6894, 0.8294)</p> <p>No Information Rate : 0.6536</p> <p>P-Value [Acc > NIR] : 0.001988</p> <p>Kappa : 0.4662</p> <p>Mcnemar's Test P-Value : 0.404657</p> <p>Sensitivity : 0.8500</p> <p>Specificity : 0.6038</p> <p>Pos Pred Value : 0.8019</p> <p>Neg Pred Value : 0.6809</p> <p>Prevalence : 0.6536</p> <p>Detection Rate : 0.5556</p> <p>Detection Prevalence : 0.6928</p> <p>Balanced Accuracy : 0.7269</p> <p>'Positive' Class : neg</p>

RNA – Hold-out	size=3 decay=0.1	0.68	<pre> [1] "Estimativas do modelo: RNA hold-out" [1] "Confusion matrix" Confusion Matrix and Statistics Reference Prediction neg pos neg 79 27 pos 21 26 Accuracy : 0.6863 95% CI : (0.6064, 0.7588) No Information Rate : 0.6536 P-Value [Acc > NIR] : 0.2234 Kappa : 0.2882 McNemar's Test P-Value : 0.4705 Sensitivity : 0.7900 Specificity : 0.4906 Pos Pred Value : 0.7453 Neg Pred Value : 0.5532 Prevalence : 0.6536 Detection Rate : 0.5163 Detection Prevalence : 0.6928 Balanced Accuracy : 0.6403 'Positive' Class : neg </pre>
----------------	------------------	------	---

O modelo que obteve o melhor desempenho foi o Random Forest com cross-validation, alcançando uma acurácia de 0,82 com o parâmetro mtry = 5. Esse resultado demonstra que a combinação da técnica Random Forest com validação cruzada e ajuste adequado do parâmetro (mtry) via grid search resultou em maior capacidade de generalização em relação aos demais modelos testados.

Com base no modelo selecionado, a imagem abaixo apresenta a predição de três novos casos realizada pelo algoritmo RF.

	↑ preg0nt ↓	glucose ↓	pressure ↓	triceps ↓	insulin ↓	mass ↓	pedigree ↓	age ↓	predict.rf ↓
1	7	149	73	36	0	33.7	0.628	51	pos
2	1	84	65	28	0	26.5	0.350	30	neg
3	11	185	66	1	2	23.5	0.674	34	pos

Abaixo são os comandos no R Studio para chegar no resultado.

```

pacotes <- c("caret","e1071", "mlbench", "mice")

# Instalando e carregando os pacotes necessarios
if(sum(as.numeric(!pacotes %in% installed.packages()))!=0){
  instalador <- pacotes[!pacotes %in% installed.packages()]
  for(i in 1:length(instalador)) {
    install.packages(instalador, dependencies = T)
    break()}
  sapply(pacotes, require, character = T)
} else {
  sapply(pacotes, require, character = T)
}

```

```
# Configurando o seed
SEED <- 2038
set.seed(SEED)

# função para dividir as bases
split_train_test <- function(df, target_var) {
  set.seed(SEED)
  indexes <- createDataPartition(df[[target_var]], p=0.80,
list=FALSE)
  train <- df[indexes,]
  test <- df[-indexes, ]
  return(list(train=train, test=test))
}

print_cf <- function(name, df_test, cf_factor, model) {
  print(paste("Estimativas do modelo: ", name))
  predict.model <- predict(model, df_test)

  print("Confusion matrix")
  print(confusionMatrix(predict.model, cf_factor))

  return(predict.model)
}

setwd("C:/Users/rodri/machine-learning/UFPR-IAAP/IAA008 -
Aprendizado de máquina")

# Diabetes

df_diabetes <- read.csv("base/10 - Diabetes/10 - Diabetes -
Dados.csv")
#View(df_diabetes)
temp_df <- df_diabetes
temp_df$num <- NULL
imp <- mice(temp_df)
df_diabetes <- complete(imp, 1)
df_diabetes[["diabetes"]] <- as.factor(df_diabetes[["diabetes"]])
View(df_diabetes)

# Divisão da base de dados
split_df <- split_train_test(df_diabetes, "diabetes")
train_diabetes = split_df$train
test_diabetes = split_df$test

diabetes_fct <- as.factor(test_diabetes$diabetes)
ctrl <- trainControl(method="cv", number=10)

# KNN
tuneGrid_knn <- expand.grid(k=c(1,3,5,7,9))
```

```
set.seed(SEED)
knn <- train(diabetes~., data=train_diabetes, method = "knn",
tuneGrid = tuneGrid_knn)
knn
predict.knn <- print_cf("KNN", test_diabetes, diabetes_fct, knn)

# RNA Hold-out
set.seed(SEED)
rna <- train(diabetes~., data=train_diabetes, method = "nnet", trace
= FALSE)
rna
predict.rna <- print_cf("RNA hold-out", test_diabetes, diabetes_fct,
rna)

# RNA CV
set.seed(SEED)
rna_cv <- train(diabetes~., data=train_diabetes, method = "nnet",
trace = FALSE, trControl = ctrl)
rna_cv
predict.rna_cv <- print_cf("RNA CV", test_diabetes, diabetes_fct,
rna_cv)

# RNA grid search
grid_rna <- expand.grid(size = seq(from=1,to=45, by=10),
decay=seq(from=0.1,to=0.9,by=0.3))
set.seed(SEED)
rna_grid <- train(diabetes~., data=train_diabetes, method = "nnet",
trace = FALSE, trControl = ctrl, tuneGrid = grid_rna)
rna_grid
predict.rna_cv_grid <- print_cf("RNA CV grid search", test_diabetes,
diabetes_fct, rna_grid)

# SVM
set.seed(SEED)
svm <- train(diabetes~., data = train_diabetes, method =
"svmRadial")
svm
predict.svm <- print_cf("SVM hold-out", test_diabetes, diabetes_fct,
svm)

# SVM CV
set.seed(SEED)
svm_cv <- train(diabetes~., data = train_diabetes, method =
"svmRadial", trControl = ctrl)
svm_cv
predict.svm_cv <- print_cf("SVM CV", test_diabetes, diabetes_fct,
svm_cv)

# SVM CV Grid
grid_cv <- expand.grid(C=c(1,2,10,50,100), sigma=c(.01,.015,.2))
set.seed(SEED)
```

```
svm_cv_grid <- train(diabetes~., data = train_diabetes, method =  
"svmRadial", trControl = ctrl, tuneGrid=grid_cv)  
svm_cv_grid  
predict.svm_cv_grid <- print_cf("SVM CV grid search", test_diabetes,  
diabetes_fct, svm_cv_grid)  
  
# Random forest  
set.seed(SEED)  
rf <- train(diabetes~., data = train_diabetes, method="rf")  
rf  
predict.rf <- print_cf("RF hold-out", test_diabetes, diabetes_fct,  
rf)  
  
# RF CV  
set.seed(SEED)  
rf_cv <- train(diabetes~., data = train_diabetes, method="rf",  
trControl = ctrl)  
rf_cv  
predict.rf_cv <- print_cf("RF CV", test_diabetes, diabetes_fct,  
rf_cv)  
  
# RF CV grid search  
grid_rf = expand.grid(mtry=c(2,5,7,9))  
set.seed(SEED)  
rf_cv_grid <- train(diabetes~., data = train_diabetes, method="rf",  
trControl = ctrl, tuneGrid = grid_rf)  
rf_cv_grid  
predict.rf_cv_grid <- print_cf("RF CV grid search", test_diabetes,  
diabetes_fct, rf_cv_grid)  
  
### Predições  
new_data <- read.csv("base/10 - Diabetes/10 - Diabetes - Dados -  
Novos Casos.csv")  
View(new_data)  
  
predict.rf <- predict(rf_cv_grid, new_data)  
new_data$diabetes <- NULL  
result <- cbind(new_data, predict.rf)  
View(result)
```

REGRESSÃO

Para o experimento de Regressão:

- Ordenar por R2 descendente, ou seja, a técnica de melhor R2 ficará em primeiro na tabela.

- Após o quadro, colocar:
 - Um resultado com 3 linhas com a predição de novos casos para a técnica/parâmetro de maior R2 (criar um arquivo com novos casos à sua escolha)
 - O Gráfico de Resíduos para a técnica/parâmetro de maior R2
 - A lista de comandos emitidos no RStudio para conseguir os resultados obtidos

Admissão

Técnica	Parâmetro	R2	Syx	Pearson	Rmse	MAE
SVM – CV	C=1 Sigma=0.1721	0.83	0.05	0.91	0.05	0.03
SVM – Hold-out	C=0.5 Sigma=0.1721	0.82	0.05	0.90	0.05	0.03
RF – Hold-out	mtry=2	0.82	0.05	0.90	0.05	0.03
RF – CV*	mtry=2	0.82	0.05	0.90	0.05	0.03
RNA – CV*	size=41 decay=0.1	0.80	0.06	0.90	0.05	0.04
RNA – Hold-out	size=5 decay=0.1	0.78	0.06	0.88	0.06	0.04
KNN	K=9	0.77	0.06	0.88	0.06	0.04


* Os modelos utilizaram cross-validation e ajuste adequado de parâmetros via grid Search.

O modelo que obteve o melhor desempenho foi o SVM com cross-validation, alcançando um R^2 de 0.83 com os parâmetros custo(C) = 1 e Sigma=0.1721. Esse resultado demonstra que a combinação da técnica SVM com validação cruzada resultou em maior capacidade de generalização em relação aos demais modelos testados.

Com base no modelo selecionado, a imagem abaixo apresenta a predição de três novos casos realizada pelo algoritmo SVM.

	GRE.Score	TOEFL.Score	University.Rating	SOP	LOR	CGPA	Research	predict.svm_cv
1	537	218	6	6.5	6.5	10.00	1	0.6883833
2	224	97	2	2.0	2.5	6.87	1	0.6881504
3	1	1	1	1.0	1.0	1.00	1	0.6883833

A figura abaixo apresenta os resíduos percentuais das previsões realizadas pelo modelo SVM com validação cruzada, aplicadas ao conjunto de teste. O resíduo percentual foi calculado como: $((\text{observado} - \text{predito}) / \text{observado} * 100)$. Esse gráfico permite avaliar a distribuição dos erros e identificar possíveis padrões ou desvios sistemáticos nas estimativas do modelo.



```
pacotes <- c("caret", "ggplot2")

# Instalando e carregando os pacotes necessarios
if(sum(as.numeric(!pacotes %in% installed.packages()))!=0){
  instalador <- pacotes[!pacotes %in% installed.packages()]
  for(i in 1:length(instalador)) {
    install.packages(instalador, dependencies = T)
    break()}
  sapply(pacotes, require, character = T)
} else {
  sapply(pacotes, require, character = T)
}

r2 <- function(predicted, real) {
  return ( 1 - (sum((predicted - real)^2) / sum((real -
mean(real))^2)))
}

syx <- function(predicted, real, p){
  n <- length(predicted)
  return (sqrt(sum((real - predicted) ^ 2) / (n - p)))
}
```



```
pearson <- function(predicted, real) {
  x_mean <- mean(real)
  y_mean <- mean(predicted)
  # cor(predicted, real, method = "pearson")
  return(sum((real - x_mean) * (predicted - y_mean)) /
  (sqrt(sum((real - x_mean) ^ 2)) * sqrt(sum((predicted - y_mean) ^
  2))))
}

print_model_stats <- function(name, df_test, target_var, model,
number_features, df_stats) {
  predicted <- predict(model, df_test)
  observed <- df_test[[target_var]]

  r2 <- r2(predicted, observed)
  syx <- syx(predicted, observed, number_features)
  pearson <- pearson(predicted, observed)
  rmse <- RMSE(predicted, observed)
  mae <- MAE(predicted, observed)

  cat("Estatísticas do modelo:", name, "\n")
  cat("R2      -->", r2, "\n")
  cat("Syx     -->", syx, "\n")
  cat("Pearson -->", pearson, "\n")
  cat("RMSE     -->", rmse, "\n")
  cat("MAE      -->", mae, "\n\n")

  new_row <- data.frame(
    Modelo = name,
    R2 = r2,
    Syx = syx,
    Pearson = pearson,
    RMSE = rmse,
    MAE = mae,
    stringsAsFactors = FALSE
  )

  return(rbind(df_stats, new_row))
}

# Configurando o seed
SEED <- 2038
set.seed(SEED)

setwd("C:/Users/rodri/machine-learning/UFPR-IAAP/IAA008 -
Aprendizado de máquina")

# Admissão
```

```
df_admissao <- read.csv("base/09 - Admissão/9 - Admissao -
Dados.csv")
df_admissao$num <- NULL
View(df_admissao)

target_var <- "ChanceOfAdmit"
number_features <- ncol(df_admissao) - 1

df_stats <- data.frame(
  Modelo = character(),
  R2 = numeric(),
  Syx = numeric(),
  Pearson = numeric(),
  RMSE = numeric(),
  MAE = numeric(),
  stringsAsFactors = FALSE
)

# Divisão da base de dados
set.seed(SEED)
indexes <- createDataPartition(df_admissao[[target_var]], p=0.80,
list=FALSE)
train <- df_admissao[indexes,]
test <- df_admissao[-indexes, ]

ctrl <- trainControl(method="cv", number=10)

# KNN
tuneGrid_knn <- expand.grid(k=c(1,3,5,7,9))
set.seed(SEED)
knn <- train(ChanceOfAdmit~., data=train, method = "knn", tuneGrid =
tuneGrid_knn)
knn
df_stats <- print_model_stats("KNN", test, target_var, knn,
number_features, df_stats)

# RNA Hold-out
set.seed(SEED)
rna <- train(ChanceOfAdmit~., data=train, method = "nnet", linout=T,
trace = FALSE)
rna
df_stats <- print_model_stats("RNA hold-out", test, target_var, rna,
number_features, df_stats)

# RNA grid search
grid_rna <- expand.grid(size = seq(from=1,to=45, by=10),
decay=seq(from=0.1,to=0.9,by=0.3))
set.seed(SEED)
rna_grid <- train(ChanceOfAdmit~., data=train, method = "nnet",
linout=T, trace = FALSE, trControl = ctrl, tuneGrid = grid_rna,
MaxNWts=10000, maxit=2000)
rna_grid
```

```
df_stats <- print_model_stats("RNA CV grid search", test,
target_var, rna_grid, number_features, df_stats)

# SVM
set.seed(SEED)
svm <- train(ChanceOfAdmit~., data = train, method = "svmRadial")
svm
df_stats <- print_model_stats("SVM hold-out", test, target_var, svm,
number_features, df_stats)

# SVM CV
set.seed(SEED)
svm_cv <- train(ChanceOfAdmit~., data = train, method = "svmRadial",
trControl = ctrl)
svm_cv
df_stats <- print_model_stats("SVM CV", test, target_var, svm_cv,
number_features, df_stats)

# SVM CV Grid
grid_cv <- expand.grid(C=c(1,2,10,50,100), sigma=c(.01,.015,.2))
set.seed(SEED)
svm_cv_grid <- train(ChanceOfAdmit~., data = train, method =
"svmRadial", trControl = ctrl, tuneGrid=grid_cv)
svm_cv_grid
df_stats <- print_model_stats("SVM CV grid search", test,
target_var, svm_cv_grid, number_features, df_stats)

# Random forest
set.seed(SEED)
rf <- train(ChanceOfAdmit~., data = train, method="rf")
rf
df_stats <- print_model_stats("RF hold-out", test, target_var, rf,
number_features, df_stats)

# RF CV
set.seed(SEED)
rf_cv <- train(ChanceOfAdmit~., data = train, method="rf", trControl
= ctrl)
rf_cv
df_stats <- print_model_stats("RF CV", test, target_var, rf_cv,
number_features, df_stats)

# RF CV grid search
grid_rf = expand.grid(mtry=c(2,5,7,9))
set.seed(SEED)
rf_cv_grid <- train(ChanceOfAdmit~., data = train, method="rf",
trControl = ctrl, tuneGrid = grid_rf)
rf_cv_grid
df_stats <- print_model_stats("RF CV grid search", test, target_var,
rf_cv_grid, number_features, df_stats)

df_stats <- df_stats[order(-df_stats$R2), ]
```

```
View(df_stats)

### Novas predições
new_data <- read.csv("base/09 - Admissão/9 - Admissao - Dados -
Novos Casos.csv")
View(new_data)

predict.svm_cv <- predict(svm_cv, new_data)
new_data$ChanceOfAdmit <- NULL
result <- cbind(new_data, predict.svm_cv)
View(result)

##### Gráfico de resíduos do melhor modelo
svm.pred <- predict(svm_cv, test)
obs <- test$ChanceOfAdmit

df_residual <- data.frame(
  Predito = svm.pred,
  Observado = obs,
  Resíduo = (((obs - svm.pred) / obs) * 100)
)

ggplot(df_residual, aes(x = Predito, y = Resíduo)) +
  geom_point(color = "steelblue") +
  geom_hline(yintercept = 0, linetype = "dashed", color = "red") +
  labs(title = "Gráfico de Resíduos do modelo SVM CV",
       x = "Chance de admissão estimado",
       y = "Resíduos (%)") +
  theme_minimal()
```

Biomassa

Técnica	Parâmetro	R2	Syx	Pearson	Rmse	MAE
SVM – CV *	C=50 Sigma=0.01	0.85	964.18	0.98	939.76	185.02
RNA – Hold-out	size=5 decay=0.1	0.75	1228.99	0.98	1197.87	265.80
KNN	K=3	0.66	1446.95	0.95	1410.31	239.84
RF – Hold-out	mtry=2	0.66	1453.65	0.96	1416.85	246.46
RF – CV	mtry=2	0.66	1458.59	0.96	1421.66	249.81
RNA – CV *	size=11 decay=0.4	0.51	1741.69	0.93	1697.59	309.09

SVM – Hold-out	C=1 Sigma=1.14	0.11	2361.98	0.44	2302.17	418.74
----------------	-------------------	------	---------	------	---------	--------


* Os modelos utilizaram cross-validation e ajuste adequado de parâmetros via grid Search.

O modelo que obteve o melhor desempenho foi o SVM com cross-validation e busca dos melhores parâmetros com grid search, alcançando um R^2 de 0.85 com os parâmetros custo(C) = 50 e Sigma=0.01. Esse resultado demonstra que a combinação da técnica SVM com validação cruzada e grid Search resultou em maior capacidade de generalização em relação aos demais modelos testados.

Com base no modelo selecionado, a imagem abaixo apresenta a predição de três novos casos realizada pelo algoritmo SVM - CV.

	dap	h	Me	predict.svm_cv_grid
1	4.4	3.0	1.00	49.428016
2	9.3	7.0	1.07	8.857247
3	5.8	2.5	1.01	58.473168

A figura abaixo apresenta os resíduos percentuais das previsões realizadas pelo modelo SVM com validação cruzada, aplicadas ao conjunto de teste. O resíduo percentual foi calculado como: $((\text{observado} - \text{predito}) / \text{observado}) * 100$. Esse gráfico permite avaliar a distribuição dos erros e identificar possíveis padrões ou desvios sistemáticos nas estimativas do modelo.



```
pacotes <- c("caret", "ggplot2")

# Instalando e carregando os pacotes necessarios
if(sum(as.numeric(!pacotes %in% installed.packages()))!=0){
  instalador <- pacotes[!pacotes %in% installed.packages()]
  for(i in 1:length(instalador)) {
    install.packages(instalador, dependencies = T)
    break()}
  apply(pacotes, require, character = T)
} else {
  apply(pacotes, require, character = T)
}

r2 <- function(predicted, real) {
  return ( 1 - (sum((predicted - real)^2) / sum((real -
mean(real))^2)))
}

syx <- function(predicted, real, p){
  n <- length(predicted)
  return (sqrt(sum((real - predicted) ^ 2) / (n - p)))
}

pearson <- function(predicted, real) {
  x_mean <- mean(real)
  y_mean <- mean(predicted)
  # cor(predicted, real, method = "pearson")
  return(sum((real - x_mean) * (predicted - y_mean)) /
(sqrt(sum((real - x_mean) ^ 2)) * sqrt(sum((predicted - y_mean) ^
2))))
}

print_model_stats <- function(name, df_test, target_var, model,
number_features, df_stats) {
  predicted <- predict(model, df_test)
  observed <- df_test[[target_var]]

  r2 <- r2(predicted, observed)
  syx <- syx(predicted, observed, number_features)
  pearson <- pearson(predicted, observed)
  rmse <- RMSE(predicted, observed)
  mae <- MAE(predicted, observed)

  cat("Estatísticas do modelo:", name, "\n")
  cat("R2      -->", r2, "\n")
  cat("Syx     -->", syx, "\n")
  cat("Pearson -->", pearson, "\n")
  cat("RMSE    -->", rmse, "\n")
  cat("MAE     -->", mae, "\n\n")

  new_row <- data.frame(
```

```
Modelo = name,
R2 = r2,
Syx = syx,
Pearson = pearson,
RMSE = rmse,
MAE = mae,
stringsAsFactors = FALSE
)

return(rbind(df_stats, new_row))
}

# Configurando o seed
SEED <- 2038
set.seed(SEED)

setwd("C:/Users/rodri/machine-learning/UFPR-IAAP/IAA008 -
Aprendizado de máquina")

# Biomassa

df <- read.csv("base/05 - Biomassa/5 - Biomassa - Dados.csv")
View(df)
df$num <- NULL
View(df)

target_var <- "biomassa"
number_features <- ncol(df) - 1

df_stats <- data.frame(
  Modelo = character(),
  R2 = numeric(),
  Syx = numeric(),
  Pearson = numeric(),
  RMSE = numeric(),
  MAE = numeric(),
  stringsAsFactors = FALSE
)

# Divisão da base de dados
set.seed(SEED)
indexes <- createDataPartition(df[[target_var]], p=0.80, list=FALSE)
df_train <- df[indexes,]
df_test <- df[-indexes, ]

ctrl <- trainControl(method="cv", number=10)

# KNN
tuneGrid_knn <- expand.grid(k=c(1,3,5,7,9))
set.seed(SEED)
knn <- train(biomassa~., data=df_train, method = "knn", tuneGrid =
tuneGrid_knn)
```

```
knn
df_stats <- print_model_stats("KNN", df_test, target_var, knn,
number_features, df_stats)

# RNA Hold-out
set.seed(SEED)
rna <- train(biomassa~., data=df_train, method = "nnet", linout=T,
trace = FALSE)
rna
df_stats <- print_model_stats("RNA hold-out", df_test, target_var,
rna, number_features, df_stats)

# RNA grid search
grid_rna <- expand.grid(size = seq(from=1,to=45, by=10),
decay=seq(from=0.1,to=0.9,by=0.3))
set.seed(SEED)
rna_grid <- train(biomassa~., data=df_train, method = "nnet",
linout=T, trace = FALSE, trControl = ctrl, tuneGrid = grid_rna,
MaxNWts=10000, maxit=2000)
rna_grid
df_stats <- print_model_stats("RNA CV grid search", df_test,
target_var, rna_grid, number_features, df_stats)

# SVM
set.seed(SEED)
svm <- train(biomassa~., data = df_train, method = "svmRadial")
svm
df_stats <- print_model_stats("SVM hold-out", df_test, target_var,
svm, number_features, df_stats)

# SVM CV
set.seed(SEED)
svm_cv <- train(biomassa~., data = df_train, method = "svmRadial",
trControl = ctrl)
svm_cv
df_stats <- print_model_stats("SVM CV", df_test, target_var, svm_cv,
number_features, df_stats)

# SVM CV Grid
grid_cv <- expand.grid(C=c(1,2,10,50,100), sigma=c(.01,.015,.2))
set.seed(SEED)
svm_cv_grid <- train(biomassa~., data = df_train, method =
"svmRadial", trControl = ctrl, tuneGrid=grid_cv)
svm_cv_grid
df_stats <- print_model_stats("SVM CV grid search", df_test,
target_var, svm_cv_grid, number_features, df_stats)

# Random forest
set.seed(SEED)
rf <- train(biomassa~., data = df_train, method="rf")
rf
```



```
df_stats <- print_model_stats("RF hold-out", df_test, target_var,
rf, number_features, df_stats)

# RF CV
set.seed(SEED)
rf_cv <- train(biomassa~., data = df_train, method="rf", trControl =
ctrl)
rf_cv
df_stats <- print_model_stats("RF CV", df_test, target_var, rf_cv,
number_features, df_stats)

# RF CV grid search
grid_rf = expand.grid(mtry=c(2,5,7,9))
set.seed(SEED)
rf_cv_grid <- train(biomassa~., data = df_train, method="rf",
trControl = ctrl, tuneGrid = grid_rf)
rf_cv_grid
df_stats <- print_model_stats("RF CV grid search", df_test,
target_var, rf_cv_grid, number_features, df_stats)

df_stats <- df_stats[order(-df_stats$R2), ]

View(df_stats)

### Novas predições
new_data <- read.csv("base/05 - Biomassa/5 - Biomassa - Dados -
Novos Casos.csv")
View(new_data)

predict.svm_cv_grid <- predict(svm_cv_grid, new_data)
new_data$biomassa <- NULL
result <- cbind(new_data, predict.svm_cv_grid)
View(result)

##### Gráfico de resíduos do melhor modelo
svm.pred <- predict(svm_cv_grid, df_test)
obs <- df_test$biomassa

df_residual <- data.frame(
  Predito = svm.pred,
  Observado = obs,
  Resíduo = ((obs - svm.pred) / obs) * 100
)

ggplot(df_residual, aes(x = Predito, y = Resíduo)) +
  geom_point(color = "steelblue") +
  geom_hline(yintercept = 0, linetype = "dashed", color = "red") +
  labs(title = "Gráfico de Resíduos do modelo SVM CV",
       x = "Biomassa estimada",
       y = "Resíduos (%)") +
  theme_minimal()
```

AGRUPAMENTO

Veículo

Lista de Clusters gerados:

10 primeiras linhas do arquivo com o cluster correspondente.

Usa 10 clusters no experimento.

Colocar a lista de comandos emitidos no RStudio para conseguir os resultados obtidos

A figura abaixo apresenta as dez primeiras linhas do resultado da associação. Para tal, foi utilizado o algoritmo *k*-means com o parâmetro de 10 clusters. Antes da aplicação do algoritmo, os dados foram previamente normalizados.

	a	Comp	Circ	DCirc	RadRa	PrAxisRa	MaxLRa	ScatRa	Elong	PrAxisRect	MaxRect	ScVarMaxis	ScVarmaxis	RaGyr	SkewMaxis	Skewmaxis	Kurtmaxis	KurtMaxis	HolIRa	tipo	veiculos_cluster
1	1	95	48	83	178	72	10	162	42	20	159	176	379	184	70	6	16	187	197	van	8
2	2	91	41	84	141	57	9	149	45	19	143	170	330	158	72	9	14	189	199	van	10
3	3	104	50	106	209	66	10	207	32	23	158	223	635	220	73	14	9	188	196	saab	7
4	4	93	41	82	159	63	9	144	46	19	143	160	309	127	63	6	10	199	207	van	2
5	5	85	44	70	205	103	52	149	45	19	144	241	325	188	127	9	11	180	183	bus	4
6	6	107	57	106	172	50	6	255	26	28	169	280	957	264	85	5	9	181	183	bus	7
7	7	97	43	73	173	65	6	153	42	19	143	176	361	172	66	13	1	200	204	bus	6
8	8	90	43	66	157	65	9	137	48	18	146	162	281	164	67	3	3	193	202	van	10
9	9	86	34	62	140	61	7	122	54	17	127	141	223	112	64	2	14	200	208	van	2
10	10	93	44	98	197	62	11	183	36	22	146	202	505	152	64	4	14	195	204	saab	5

```
# Configurando o seed
SEED <- 2038
set.seed(SEED)

setwd("C:/Users/rodri/machine-learning/UFPR-IAAP/IAA008 -
Aprendizado de máquina")

# Veículos

df_veiculos <- read.csv("base/06 - Veiculos/6 - Veiculos -
Dados.csv")
View(df_veiculos)

# Ignora a coluna de id e coluna de classes
df_veiculos_clean <- df_veiculos[, -c(1, ncol(df_veiculos))]
df_veiculos_clean = scale(df_veiculos_clean)
View(df_veiculos_clean)

veiculos_cluster <- kmeans(df_veiculos_clean, 10)
veiculos_cluster

table(veiculos_cluster$cluster, df_veiculos$tipo)

resultado <- cbind(df_veiculos, veiculos_cluster$cluster)
```

View(resultado)

REGRAS DE ASSOCIAÇÃO

Musculação

Regras geradas com uma configuração de Suporte e Confiança.

Colocar a lista de comandos emitidos no RStudio para conseguir os resultados obtidos

A figura abaixo apresenta as 30 primeiras regras geradas pela execução do algoritmo Apriori na base de dados de musculação. O algoritmo foi executado com suporte mínimo de 0,001 e confiança mínima de 0,7.

```
> inspect(sort(rules, by="confidence"))
```

	lhs	rhs	support	confidence	coverage	lift	count
[1]	{Crucifixo}	=> {Afundo}	0.077	1.00	0.077	2.9	2
[2]	{Crucifixo}	=> {Gemeos}	0.077	1.00	0.077	1.5	2
[3]	{Crucifixo}	=> {LegPress}	0.077	1.00	0.077	1.2	2
[4]	{Adutor}	=> {Agachamento}	0.115	1.00	0.115	3.2	3
[5]	{Adutor}	=> {LegPress}	0.115	1.00	0.115	1.2	3
[6]	{Flexor}	=> {Esteira}	0.077	1.00	0.077	2.2	2
[7]	{Flexor}	=> {Extensor}	0.077	1.00	0.077	2.0	2
[8]	{Flexor}	=> {Bicicleta}	0.077	1.00	0.077	1.9	2
[9]	{Flexor}	=> {LegPress}	0.077	1.00	0.077	1.2	2
[10]	{Agachamento}	=> {LegPress}	0.308	1.00	0.308	1.2	8
[11]	{Afundo}	=> {Gemeos}	0.346	1.00	0.346	1.5	9
[12]	{Afundo, Crucifixo}	=> {Gemeos}	0.077	1.00	0.077	1.5	2
[13]	{Crucifixo, Gemeos}	=> {Afundo}	0.077	1.00	0.077	2.9	2
[14]	{Afundo, Crucifixo}	=> {LegPress}	0.077	1.00	0.077	1.2	2
[15]	{Crucifixo, LegPress}	=> {Afundo}	0.077	1.00	0.077	2.9	2
[16]	{Crucifixo, Gemeos}	=> {LegPress}	0.077	1.00	0.077	1.2	2
[17]	{Crucifixo, LegPress}	=> {Gemeos}	0.077	1.00	0.077	1.5	2
[18]	{Adutor, Agachamento}	=> {LegPress}	0.115	1.00	0.115	1.2	3
[19]	{Adutor, LegPress}	=> {Agachamento}	0.115	1.00	0.115	3.2	3
[20]	{Esteira, Flexor}	=> {Extensor}	0.077	1.00	0.077	2.0	2
[21]	{Extensor, Flexor}	=> {Esteira}	0.077	1.00	0.077	2.2	2
[22]	{Esteira, Flexor}	=> {Bicicleta}	0.077	1.00	0.077	1.9	2
[23]	{Bicicleta, Flexor}	=> {Esteira}	0.077	1.00	0.077	2.2	2
[24]	{Esteira, Flexor}	=> {LegPress}	0.077	1.00	0.077	1.2	2
[25]	{Flexor, LegPress}	=> {Esteira}	0.077	1.00	0.077	2.2	2
[26]	{Extensor, Flexor}	=> {Bicicleta}	0.077	1.00	0.077	1.9	2
[27]	{Bicicleta, Flexor}	=> {Extensor}	0.077	1.00	0.077	2.0	2
[28]	{Extensor, Flexor}	=> {LegPress}	0.077	1.00	0.077	1.2	2
[29]	{Flexor, LegPress}	=> {Extensor}	0.077	1.00	0.077	2.0	2
[30]	{Bicicleta, Flexor}	=> {LegPress}	0.077	1.00	0.077	1.2	2

```
#install.packages('arules', dep=T)
library(arules)

# Configurando o seed
SEED <- 2038
set.seed(SEED)

setwd("C:/Users/rodri/machine-learning/UFPR-IAAP/IAA008 -
Aprendizado de máquina")
```



UFPR – Universidade Federal do Paraná
Setor de Educação Profissional e Tecnológica
Especialização em Inteligência Artificial Aplicada
Disciplina: Aprendizado de Máquina – Prof Jaime Wojciechowski



```
atividades <- read.transactions(  
  file = "base/12 - Regras de Associacao - Praticas/12 - Regras de  
Associacao - Praticas - 2 - Musculacao/2 - Musculacao - Dados.csv",  
  format = "basket",  
  sep=";"  
)  
  
inspect(head(atividades, 3))  
itemFrequencyPlot(atividades, topN = 10, type='absolute')  
  
summary(atividades)  
  
set.seed(SEED)  
rules <- apriori(atividades, parameter = list(supp = 0.001, conf =  
0.7, minlen=2))  
summary(rules)  
  
options(digits=2)  
inspect(sort(rules, by="confidence"))
```